ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΣΗΜΑΤΩΝ, ΕΛΕΓΧΟΥ ΚΑΙ ΡΟΜΠΟΤΙΚΗΣ

ΨΗΦΙΑΚΗ ΕΠΕΞΕΡΓΑΣΙΑ ΣΗΜΑΤΟΣ

ΚΩΔΙΚΟΠΟΙΗΣΗ ΣΗΜΑΤΩΝ ΜΟΥΣΙΚΗΣ ΒΑΣΕΙ ΤΟΥ ΨΥΧΟΑΚΟΥΣΤΙΚΟΥ ΜΟΝΤΕΛΟΥ
PERCEPTUAL AUDIO CODING

ΑΓΓΕΛΟΣ ΚΑΜΑΡΙΑΔΗΣ

ΜΕΡΟΣ 1 - ΨΥΧΟΑΚΟΥΣΤΙΚΟ ΜΟΝΤΕΛΟ 1

Προεπεξεργασία του σήματος

Αρχικά, διαβάστηκε με τη χρήση της python, το σήμα μουσικής του αρχείου music_dsp2026.wav και μετατράπηκε από stereo format σε mono. Η τυπική μέθοδος στην ψηφιακή επεξεργασία σημάτων για μετατροπή ενός ακουστικού σήματος από stereo format σε mono, είναι ο υπολογισμός του μέσου όρου των δύο καναλιών. Δηλαδή, η άθροιση του αριστερού και δεξιού καναλιού, και έπειτα η διαίρεσή του αθροίσματος δια 2.

Εν συνέχεια, κανονικοποιήθηκε σε όλο το μήκος του, διαιρώντας τα δείγματα του με την απόλυτη μέγιστη τιμή του σήματος, έτσι ώστε καθ΄ όλη τη διάρκεια του να έχει τιμές μεταξύ [−1, 1].

Διαιρώντας με το np.max(np.abs()) εξασφαλίζουμε ότι η υψηλότερη κορυφή του σήματος θα είναι το 1 ή το −1, και όλα τα υπόλοιπα δείγματα θα κλιμακωθούν αναλογικά.

Τέλος, κάνουμε την παραδοχή πως για όλα τα ακόλουθα βήματα, η παραθυροποιήση του σήματος θα πραγματοποιηθεί χρησιμοποιώντας N = 512 δείγματα και ανάλυση σε κάθε πλαίσιο.

Τα αποτελέσματα φαίνονται παρακάτω, στο output του terminal του PyCharm όπου και εκτελέστηκε ο κώδικας (code_1.0-1.1.py). Στο ouput, συμπεριλαμβάνονται και τα αποτλέσματα του επόμενο βήματος, καθώς ο κώδικας για αυτά είναι κοινός.

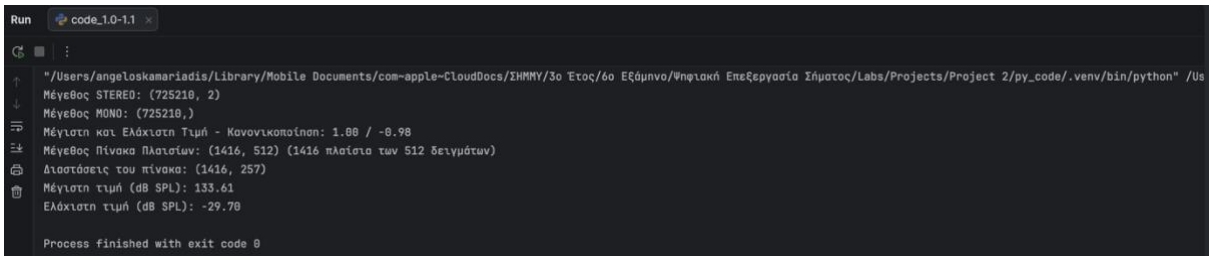

Φασματική ανάλυση

Στόχος μας σε αυτό το βήμα, είναι να αποκτήσουμε μία υψηλής ανάλυσης εκτίμηση του φάσματος του σήματος, εκφρασμένο σε μονάδες SPL (Sound Pressure Level).

Αρχικά, ορίζουμε την κλίμακα Bark σύμφωνα με την παρακάτω εξίσωση:

$$b(f) = 13\arctan(0.00076f) + 3.5\arctan[\frac{(f)}{7500}^2]$$

και εν συνεχεία, υπολογίζουμε το N - σημείων φάσμα ισχύος P(k) του σήματος, με N = 512 δείγματα, χρησιμοποιώντας την εξίσωση:

$$P(k) = PN + 10log_{10}\left|\sum_{n=0}^{N-1} w(n)x(n)e^{-j\frac{2\pi kn}{N}}\right|^2 \ \forall\ 0 \le k \le \frac{N}{2}$$

όπου PN = 90.302 dB και είναι η σταθερά κανονικοποίησης και w(n) το hanning window που ορίζεται ως:

$$w(n) = \frac{1}{2}(1 - cos(\frac{2\pi n}{N}))$$

Τα αποτελέσματα φαίνονται παρακατω.

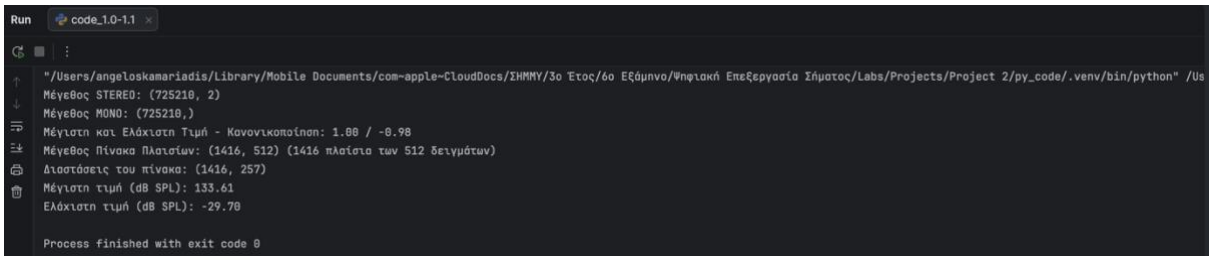

Εντοπισμός μασκών τόνων και θορύβου (Maskers)

Εφόσον έχουμε υπολογίσει το φάσμα ισχύος P(k), εν συνεχεία θα εντοπίσουμε ανά critical band, τοπικά μέγιστα (μάσκες) τα οποία είναι μεγαλύτερα από τις γειτονικές τους συχνότητες τουλάχιστον κατα 7 dB. Το εύρος της γειτονιάς υπολογισμού των μασκών διαφέρει ανά διακριτή συχνότητα k, όπως φαίνεται στην παρακάτω εξίσωση:

$$\Delta_k = \begin{cases} 2, \forall\ 2 \le k \le 63, (0{,}17 - 5{,}5kHz) \\ [2{,}3]63, \forall\ 63 \le k \le 127, (5{,}5 - 11kHz) \\ [2{,}6]127, \forall\ 127 \le k \le 250, (11 - 20kHz) \end{cases}$$

Στις υψηλές συχνότητες οι μάσκες καλύπτουν ευρύτερες γειτονιές.

Η συνάρτηση $S_T(k) = \begin{cases} 0, \forall\ k \notin [2{,}250) \\ P(k) > P(k \pm 1)\ \Lambda\ P(k) > P(k \pm \Delta_k) + 7dB, \forall\ k \in [2{,}250) \end{cases}$

επιστρέφει boolean τιμές {0, 1} που προσδιορίζουν αν στη θέση k υπάρχει τονική μάσκα. Κάθε θέση k στην οποία η ST έχει λογική τιμή 1 αντιστοιχεί σε μία τονική μάσκα που καλύπτει τις γειτονικές συχνότητες.

Για την εύρεση και την αναπαράσταση των μασκών του θορύβου δίνεται από την εκφώνηση, ο προυπολογισμένος
πίνακας P_NM-26 για το κάθε παράθυρο ανάλυσης.

Τέλος, υπολογίστηκε η ισχύς κάθε τονικής μάσκας, με τη χρήση της εξίσωσης:

$$P_{TM}(k) = \begin{cases} 10log_{10}[10^{0,1(P(k-1))} + 10^{0,1(P(k))} + 10^{0,1(P(k+1))}](dB), \alpha\nu\ S_T(k) = 1 \\ 0, \alpha\nu\ S_T(k) = 1 \end{cases}$$

Οι θέσεις των τονικών μασκών και το φάσμα ισχύος τους, φαίνονται παρακάτω.

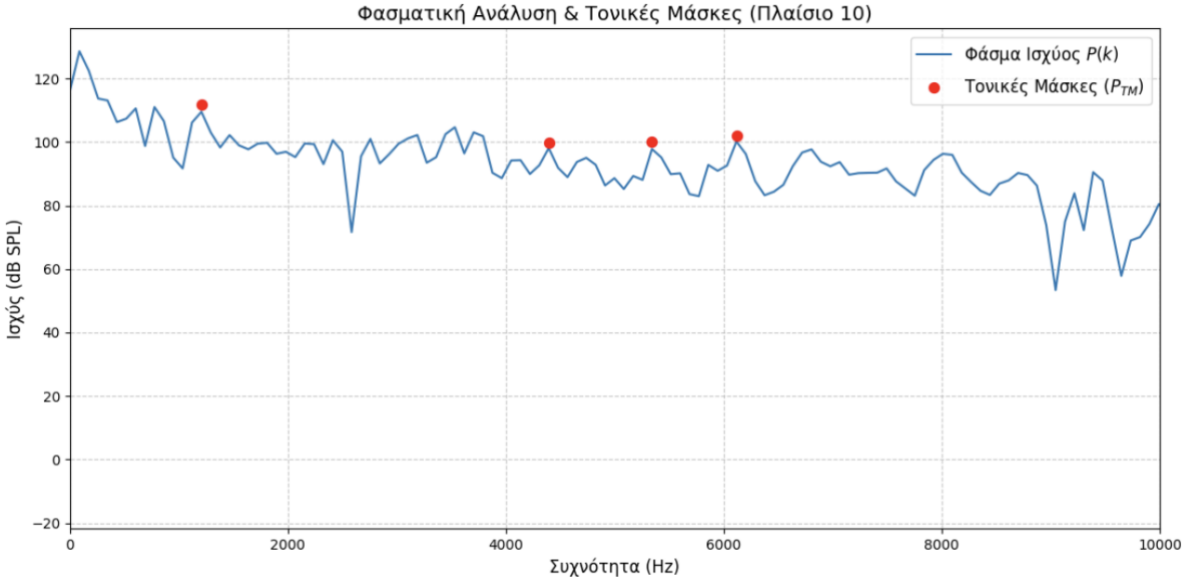

Αναλύοντας την οπτικοποίηση του πλαισίου 10, εξάγουμε τα παρακάτω συμπεράσματα:

<u>Επιτυχής εφαρμογή του κριτηρίου των 7dB</u>
Στις χαμηλές συχνότητες (0 - 500 Hz) παρατηρούμε ότι το φάσμα παρουσιάζει την μέγιστη ενέργεια του εφόσον ξεπερνά τα 120 dB SPL. Όμως, ο αλγόριθμος δεν τοποθέτησε καμία κόκκινη κουκκίδα (τονική μάσκα) εκεί για τον λόγο ότι ολόκληρη εκείνη η περιοχή έχει υψηλή ενέργεια. Το τοπικό μέγιστο δεν ξεχωρίζει κατά 7dB από τις γειτονικές του συχνότητες. Δεν είναι δηλαδή ένας απομονωμένος και καθαρός τόνος, αλλά μια ευρύτερη ζώνη χαμηλών συχνοτήτων. Το γεγονός αυτό, αποδεικνύει πως ο κώδικάς δεν μπερδεύει τα απλά τοπικά μέγιστα με τις πραγματικές τονικές μάσκες.

<u>Εντοπισμός των πραγματικών τόνων</u>
Ο αλγόριθμος εντόπισε επιτυχώς 4 τονικές μάσκες στο φάσμα 0 - 10 kHz, οι οποίες βρίσκονται (περίπου) στις συχνότητες: 1.2 kHz, 4.4 kHz, 5.4 kHz και 6.1 kHz αντίστοιχα. Αυτές οι κορυφές, παρόλο που έχουν χαμηλότερη απόλυτη ισχύ (περίπου στα 100-110 dB SPL) από τις χαμηλές συχνότητες, είναι πολύ αιχμηρές, αφού παρουσιάζονται απότομα από το περιβάλλον τους, ικανοποιώντας τον κανόνα των +7dB.

<u>Ψυχοακουστική ερμηνεία</u>
Στο χρονικό σημείο των 10 χιλιοστών του δευτερολέπτου (Πλαίσιο 10), ο ανθρώπινος εγκέφαλος θα εστιάσει την προσοχή του σε αυτούς τους 4 κυρίαρχους τόνους. Επειδή αυτοί οι τόνοι είναι τόσο διακριτοί και ισχυροί, θα προκαλέσουν masking στις γειτονικές, και πιο αδύναμες συχνότητες.

Μείωση και αναδιοργάνωση των μασκών

Τώρα, επεκτείνοντας τους προηγούμενους κώδικες, μειώνουμε τον αριθμό των μασκών, χρησιμοποιώντας τους πίνακες P_TMc-26, P_NMc-26 οι οποίοι περιέχουν τις τονικές μάσκες P_TMc και τις μάσκες θορύβου P_NMc για το κάθε παράθυρο ανάλυσης, μετά τη μείωση και την αναδιοργάνωση.

Οι μειωμένες τονικές μάσκες και οι μάσκες θορύβου, απεικονίζονται παρακάτω.

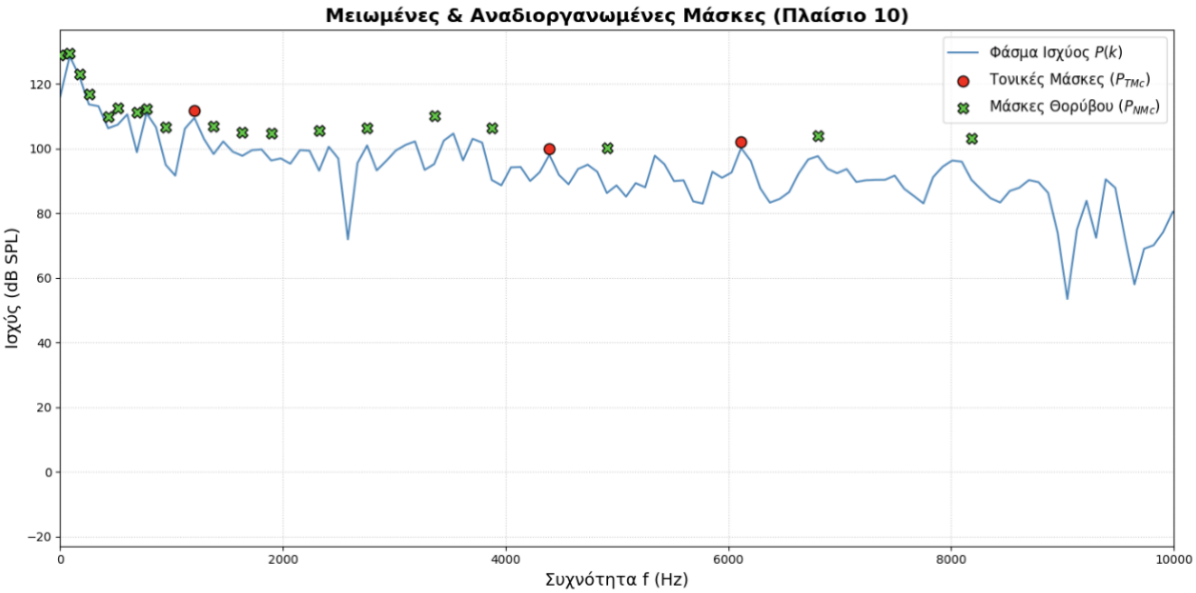

<u>Πόσες μάσκες έμειναν και γιατί</u>

Στο νέο γράφημα, παρατηρούμε πως έχουν μείνει 3 από τις 4 μάσκες, καθώς η μάσκα που βρισκόταν (περίπου) στα 5.4 kHz έφυγε. Αυτό συνέβει γιατί ο αλγόριθμος αναδιοργάνωσης έκρινε ότι αυτή η κορυφή βρισκόταν πολύ κοντά σε κάποια άλλη ισχυρότερη μάσκα και άρα θα επικαλυπτόταν από αυτήν. Εφόσον το αυτί μας δεν θα την άκουγε ούτως ή άλλως, ο αλγόριθμος την έσβησε για να γλιτώσει περιττούς υπολογισμούς.

<u>Συμπεριφορά των μασκών θορύβου</u>

Παρατηρούμε πως τα πράσινα x συγκεντρώνονται σε περιοχές του φάσματος που δεν έχουν αιχμηρές κορυφές. Αντιστοιχούν ουσιαστικά στον θόρυβο βάθους ή στην ενέργεια ευρέος φάσματος μέσα σε κάθε critical band. Τέλος, παρατηρούμε πως στις πολύ χαμηλές συχνότητες (0 - 1000 Hz), όπου το σήμα έχει τεράστια ενέργεια αλλά όχι καθαρούς τόνους, έχουμε πάρα πολλές μάσκες θορύβου, ενώ στις ψηλότερες συχνότητες, αραιώνουν σημαντικά.

Υπολογισμός των δυο διαφορετικών κατωφλίων κάλυψης (Individual Masking Thresholds)

Μετά τη μείωση του αριθμού των μασκών, υπολογίζουμε τα δύο διαφορετικά κατώφλια κάλυψης, τα οποία αντιπροσωπεύουν το ποσοστό κάλυψης στο σημείο i το οποίο προέρχεται από την μάσκα τόνου ή θορύβου στο σημείο j. Τα κατώφλια υπολογίζονται ως εξής:

$$T_{TM}(i,j) = P_{TM}(j) - 0{,}275b(j) + SF(i,j) - 6{,}025(dB\ SPL)$$
$$T_{NM}(i,j) = P_{NM}(j) - 0{,}175b(j) + SF(i,j) - 2{,}025(dB\ SPL)$$

όπου το $P_{TM}(j)$ και $P_{NM}(j)$ η ισχύς των μασκών, στο σημείο j και b(j) οι συχνότητες στη κλίμακα Bark.

Η συνάρτηση SF(i, j) υπολογίζει την έκταση της κάλυψης από το σημείο j στο οποίο βρίσκεται η μάσκα έως το σημείο i το οποίο υφίσταται κάλυψη και, για την περίπτωση των τονικών μασκών, και δίνεται στην εκφώνηση.

Παρακάτω, απεικονίζεται η επίδραση της συνάρτησης διασποράς καθώς το ατομικό κατώφλι συγκάλυψης.

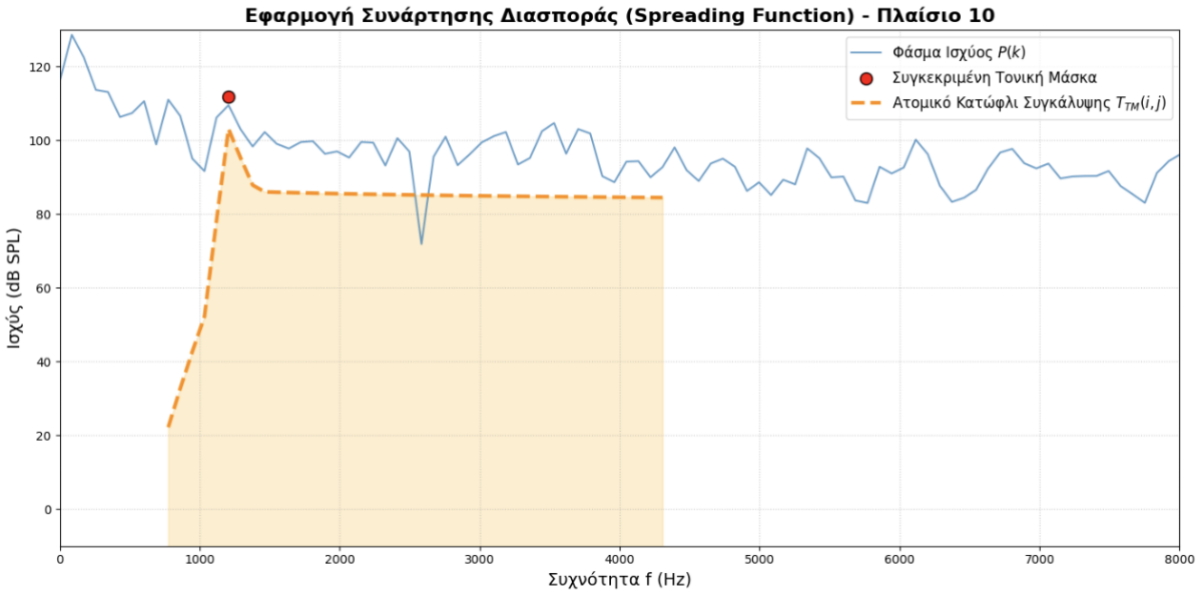

Αναλύοντας την πιο πάνω οπτικοποίηση, εξάγουμε τα παρακάτω συμπεράσματα:

<u>Ασυμμετρία ομπρέλας</u>

Παρατηρώντας την πορτοκαλί διακεκομμένη γραμμή, βλέπουμε πως απουσιάζει η συμμετρία γύρω από την κόκκινη κουκκίδα. Στις χαμηλότερες συχνότητες, η καμπύλη κατεβαίνει απότομα. Αυτό σημαίνει ότι ο τόνος μας στα 1.2 kHz δυσκολεύεται πολύ να κρύψει ήχους που βρίσκονται σε πιο μπάσες συχνότητες από αυτόν. Στις υψηλότερες συχνότητες, η καμπύλη σβήνει πολύ ομαλά και απλώνεται σε ένα τεράστιο εύρος, φτάνοντας σχεδόν μέχρι τα (περίπου) 4.3 kHz. Άρα, ένας δυνατός μπάσος ή μεσαίος ήχος σκεπάζει πανεύκολα τα πιο πρίμα στοιχεία του ήχου.

<u>Η τυφλή ζώνη του αυτιού</u>

Όλη η περιοχή με το απαλό πορτοκαλί χρώμα κάτω από την καμπύλη είναι πρακτικά η άχρηστη πληροφορία για αυτό το χιλιοστό του δευτερολέπτου. Οποιαδήποτε κορυφή της μπλε γραμμής τυχαίνει να βρίσκεται χαμηλότερα από την πορτοκαλί γραμμή, ο άνθρωπος δεν είναι ικανός να την ακούσει.

<u>Το όριο των 8 Bark</u>

Στις χαμηλότερες συχνότητες, η πορτοκαλί γραμμή κόβεται απότομα. Αυτό οφείλεται στον περιορισμό της γειτονιάς Δ_b που ορίζει η εκφώνηση.

Υπολογισμός του συνολικού κατωφλίου κάλυψης (Global MaskingThreshold)

Τα ξεχωριστά κατώφλια κάλυψης τα οποία υπολογίστηκαν προηγουμένως, μπορούν να συνδυαστούν για την δημιουργία του συνολικού κατωφλίου, σε κάθε διακριτή συχνότητα ξεχωριστά. Το συνολικό κατώφλι $T_g(i)$ για κάθε πλαίσιο ανάλυσης υπολογίζεται αθροιστικά από την εξίσωση:

$$T_g(i) = 10\log_{10}[10^{0,1T_q(i)} + \sum_{l=0}^{255} 10^{0,1T_{TM}(i,l)} + \sum_{m=0}^{255} 10^{0,1T_{NM}(i,m)}] \text{ dB SPL}$$

όπου το $T_q(i)$ είναι το Absolute Threshold of Hearing (ATH) σε κάθε διακριτή συχνότητα i, $T_{TM}(i, l)$ και $T_{NM}(i,m)$ τα ξεχωριστά κατώφλια κάλυψης των τόνων και του θορύβου αντίστοιχα, όπως υπολογίστηκαν πιο πάνω. Για τον υπολογισμό των επιμέρους κατωφλίων κάλυψης $T_{TM}(i, \ell)$ και $T_{NM}(i,m)$ για κάθε critical band, που αντιστοιχεί στις διαφορετικές μάσκες, αθροίζονται τα επιμέρους κατώφλια σε κάθε πλαίσιο ανάλυσης ξεχωριστά.

Το συνολικό κατώφλι συγκάλυψης για το πλαίσιο 10 απεικονίζεται παρακάτω.

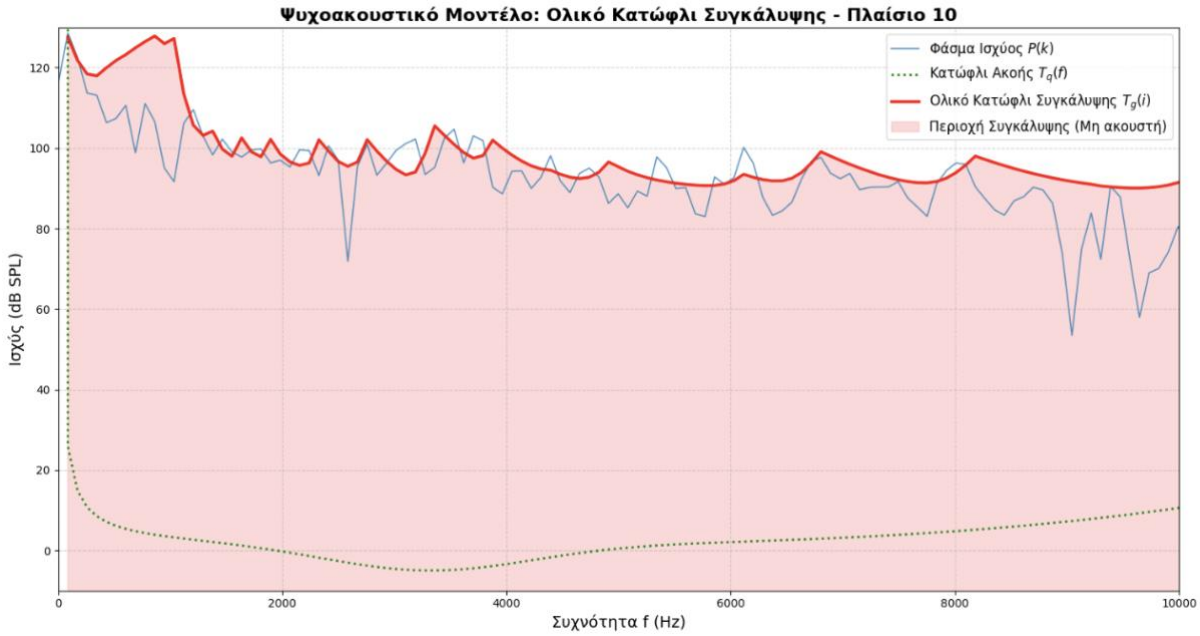

Από την πιο πάνω οπτικοποίηση, εξάγουμε τα παρακάτω συμπεράσματα.

<u>Η αδυναμία του ανθρώπινου αυτιού</u>

Παρατηρούμε πως ένα πολύ μεγάλο μέρος της μπλε γραμμής, δηλαδή του πραγματικού ακουστικού σήματος, βρίσκεται βυθισμένο μέσα στην κόκκινη σκιασμένη περιοχή. Όλη αυτή η ενέργεια, αν και υπάρχει στο αρχείο .wav, καλύπτεται από τους γειτονικούς, ισχυρότερους τόνους. Εφόσον όμως ο άνθρωπος δεν μπορεί να την ακούσει, σημαίνει πως ο κωδικοποιητής μπορεί να αφαιρέσει εντελώς αυτές τις πληροφορίες και εμείς δεν θα καταλάβουμε καμία απολύτως διαφορά στην ποιότητα του ήχου.

Κατώφλι ακοής
Η πράσινη διακεκομμένη γραμμή, ξεκινάει πολύ ψηλά στις χαμηλές συχνότητες, άρα χρειαζόμαστε πολλά dB για να ακούσουμε ένα βαθύ μπάσο, αλλά μετά μειώνεται απότομα. Η εξέλιξη του ανθρώπου έκανε τα αυτιά μας υπερευαίσθητα σε αυτή την περιοχή. Για αυτό το κατώφλι εκεί πέφτει ακόμα και κάτω από τα 0 dB SPL.

Signal to Mask Ratio
Αν κοιτάξουμε προσεκτικά, μόνο κάποιες αιχμηρές κορυφές της μπλε γραμμής καταφέρνουν να τρυπήσουν το κόκκινο ταβάνι, δηλαδή το ολικό κατώφλι και να βγουν στον καθαρό αέρα. Αυτές τις συχνότητες τις ακούμε πεντακάθαρα.

ΜΕΡΟΣ 2 - ΧΡΟΝΟ-ΣΥΧΝΟΤΙΚΗ ΑΝΑΛΥΣΗ ΜΕ ΣΥΣΤΟΙΧΙΑ ΖΩΝΟΠΕΡΑΤΩΝ ΦΙΛΤΡΩΝ

Σε αυτό το μέρος, φιλτράρουμε τα παράθυρα x(n) του σήματος με τη συστοιχία φίλτρων ανάλυσης $h_k(n)$ και σύνθεσης $g_k(n)$. Στόχος είναι η δημιουργία μιας συνάρτησης που υλοποιεί τη διαδικασία του παρακάτω σχήματος:

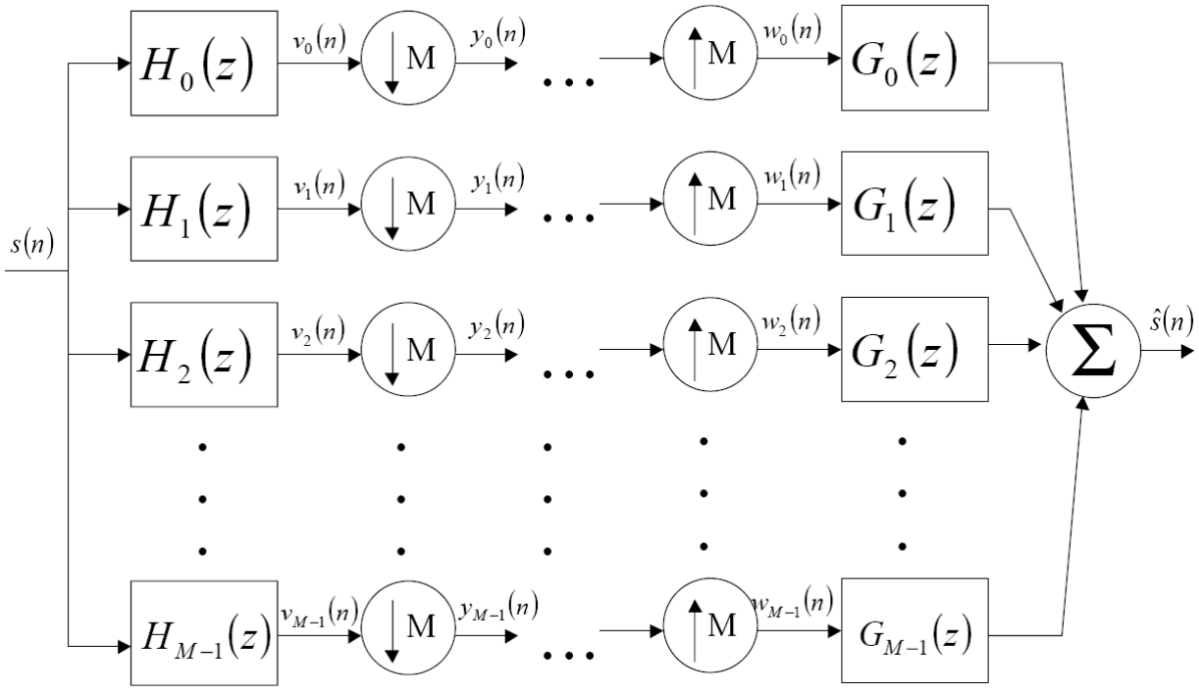

η οποία λαμβάνει ως είσοδο το κάθε πλαίσιο ανάλυσης x(n), τη συστοιχία φίλτρων και το συνολικό κατώφλι κάλυψης που υπολογίστηκε στο Μέρος 1. Η έξοδος της συνάρτησης είναι το ανακατασκευασμένο σήμα $\hat{x}(n)$ και ο αριθμός των bits που χρησιμοποιήθηκαν για τη δημιουργία του.

Συστοιχία ζωνοπερατών φίλτρων (Filterbank)

Για την ανάλυση του σήματος στις κρίσιμες συνιστώσες του ανά χρονικό πλαίσιο, χρησιμοποιούνται συστοιχίες ζωνοπερατών φίλτρων, όπως αυτές παροσιάζονται στο πιο πάνω σχήμα. Τα φίλτρα σχεδιάστηκαν βάσει του Modified Discrete Cosine Transform

(MDCT), ο οποίος είναι πλήρως αντιστρέψιμος και δεν εισάγει λάθη στην κωδικοποίηση του σήματος.

Στο στάδιο της κωδικοποίησης και αποκωδικοποίησης του συστήματος συμπίεσης που υλοποιείται στην άσκηση χρησιμοποιούνται M = 32 φίλτρα ανάλυσης των οποίων οι κρουστικές αποκρίσεις δίνονται από την εξίσωση:

$$h_k(n) = sin[(n + \frac{1}{2})\frac{\pi}{2M}]\sqrt{\frac{2}{M}}cos[\frac{(2n + M + 1)(2k + 1)\pi}{4M}]$$

και M = 32 φίλτρα σύνθεσης των οποίων οι ξρουστικές αποκρίσεις δίνονται από την εξίσωση:

$$g_k(n) = h_k(n)(2M - 1 - n)$$

Ανάλυση με Συστοιχία Φίλτρων

Σε αυτό το βήμα, πραγματοποιούμε συνέλιξη του σήματος x(n) με τα φίλτρα σύνθεσης $h_k(n)$ και έπειτα, υποδειγματοληψία του φιλτραρισμένου σήματος. Η ακολουθία εξόδου δίνεται από την εξίσωση:

$$u_k(n) = h_k(n) * x(n) = \sum_{m=0}^{L-1} x(n - m)h_k(m), \forall\, k = 0, \ldots, M - 1$$

Χρησιμοποιώντας την Python, υλοποιήσαμε το στάδιο ανάλυσης υποζωνών του κωδικοποιητή, όπου το αρχικό ευρυζωνικό σήμα διαχωρίζεται σε 32 narrowband σήματα μέσω μιας συστοιχίας ζωνοπερατών φίλτρων (όπως αυτή απεικονίζεται πιο πάνω) διαμόρφωσης συνημιτόνου (MDCT). Έπειτα, αφού σχεδιάσαμε τα φίλτρα με χρήση ενός ημιτονικού παραθύρου για την ελαχιστοποίηση της φασματικής διαρροής, εφαρμόσαμε γραμμική συνέλιξη του σήματος με αυτά και προβήκαμε σε κρίσιμη υποδειγματοληψία (decimation κατά παράγοντα = 32), διατηρώντας σταθερό τον συνολικό όγκο των δεδομένων χωρίς απώλεια πληροφορίας. Τυχόν σφάλματα aliasing από τις μη ιδανικές, αλληλεπικαλυπτόμενες ζώνες αντιμετωπίζονται εγγενώς μέσω της ιδιότητας TDAC (Time-Domain Aliasing Cancellation) του MDCT, οποίος όπως αναφέρει η εκφώνηση, εγγυάται τέλεια ανακατασκευή, καταλήγοντας τελικά σε έναν πλήρη φασματικό αποσυσχετισμό του σήματος, ο οποίος μας επιτρέπει πλέον να εφαρμόσουμε ανεξάρτητο, στοχευμένο κβαντισμό στην κάθε υποζώνη βάσει του ολικού κατωφλίου του ψυχοακουστικού μοντέλου.

Παρακάτω, φαίνεται το output του κώδικα Python στο terminal του PyCharm, ο οποίος χρησιμοπιήθηκε για τον σχεδιασμό του γραφήματος που ακολουθεί.

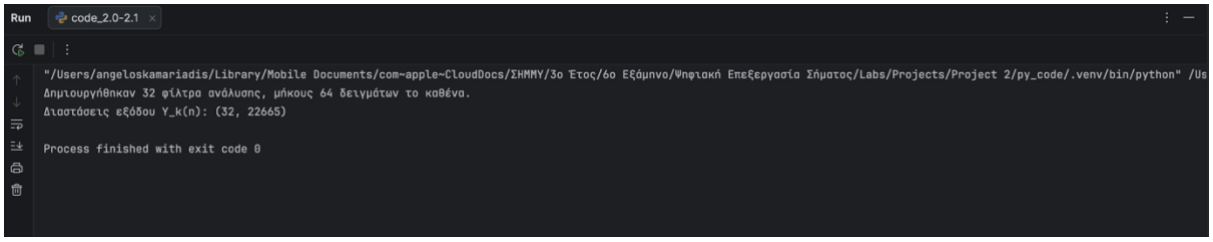

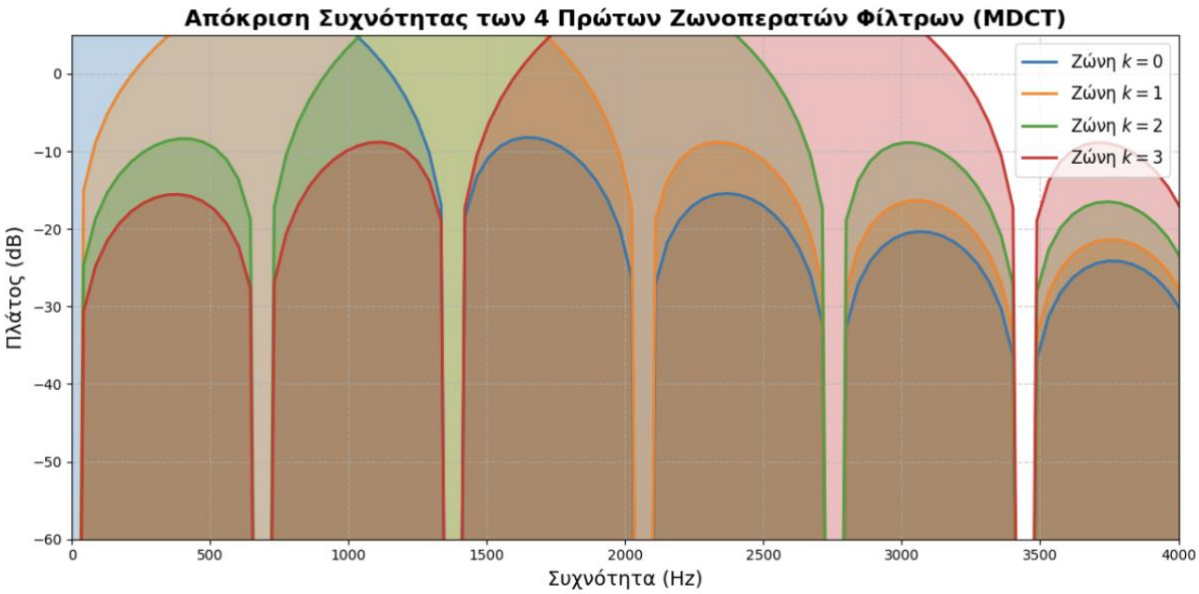

Από το πιο πάνω γράφημα εξάγουμε τα εξής συμπεράσματα:

<u>Ο Διαχωρισμός σε κομμάτια</u>
Κάθε χρώμα αντιπροσωπεύει και ένα διαφορετικό φίλτρο. Εδώ παρατηρούμε τα 4 πρώτα από τα 32 συνολικά. Όπως φαίνεται κάθε φίλτρο έχει μια κορυφή η οποία βρίσκεται σε διαφορετική συχνότητα. Η μπλε ζώνη αναλαμβάνει τις πολύ χαμηλές συχνότητες. Η πορτοκαλί τις αμέσως επόμενες. Η πράσινη τις επόμενες, κ.ο.κ. Ουσιαστικά, ο ήχος μπαίνει σε αυτό το σύστημα και μοιράζεται σε αυτά τα διαδοχικά κανάλια.

<u>Aliasing</u>
Αν τα φίλτρα ήταν ιδανικά, το γράφημα θα έμοιαζε με ορθογώνια σχήματα που το ένα θα ξεκινούσε εκεί που τελειώνει το άλλο. Ωστόσο, όπως βλέοπουμε, οι καμπύλες απλώνονται και αλληλοεπικαλύπτονται.

<u>MDCT (Time-Domain Aliasing Cancellation)</u>
Όπως αναφέρθηκε στην εκφώνηση, ο μετασχηματισμός MDCT είναι πλήρως αντιστρέψιμος. Παρόλο που το γράφημα δείχνει ότι τα φίλτρα μας διαρρέουν το ένα στο άλλο, ο αλγόριθμος MDCT, όταν έρθει η ώρα να ξαναενώσουμε τον ήχο (MP3), μας βοηθά να αλληλοαναιρέσουμε μαθηματικά τα λάθη αυτά (TDAC). Άρα, επί του πρακτέου, δεν μας ενδιαφέρει καθόλου που τα φίλτρα δεν είναι τέλεια ορθογώνια.

Κβαντοποίηση

Σε αυτό το βήμα, υλοποιήσαμε την πραγματική συμπίεση, δηλαδή την μείωση δεδομένων του ηχητικού σήματος, συνδέοντας τα φίλτρα με το Ψυχοακουστικό Μοντέλο του Μέρους 1.

Κάθε ψηφιακός κωδικοποιητής, έχει έναν κβαντιστή, ο οποίος αντιστοιχεί τις τιμές των δειγμάτων μίας διακριτής ακολουθίας σε αριθμημένα επίπεδα κβάντισης.

Εμείς, υλοποιήσαμε έναν προσαρμοζόμενο ομοιόμορφο κβαντιστή 2^{B_k} επιπέδων, όπου B^k ο αριθμός των bits κωδικοποίησης ανά δείγμα της ακολουθίας $y_k(n)$ στο τρέχον πλαίσιο ανάλυσης x(n) του σήματος, ο οποίος και υπολογίζεται από τον τύπο:

$$B_k = int(log_2(\frac{R}{min(T_g(i))}) - 1)$$

όπου $T_g(i)$ το συνολικό κατώφλι κάλυψης του ψυχοακουστικού μοντέλου για το πλαίσιο ανάλυσης και R = 2B το πλήθος των βαθμίδων έντασης του αρχικού σήματος s(n), κωδικοποιημένο στα B bits ανά δείγμα. Το $T_g(i)$ ορίζεται στο διάστημα ορισμού του φίλτρου ανάλυσης το οποίο δίνεται στην εκφώνηση.

Το βήμα κβαντισμού Δ, ρυθμίζεται βάσει του B_k και του εκάστοτε πεδίου τιμών $[x_{min}, x_{max}]$ στο τρέχον πλαίσιο ανάλυσης και δίνεται από την εξίσωση:

$$\Delta = \frac{x_{max} - x_{min}}{2^{B_k}}$$

Τέλος, πειραματιστήκαμε με έναν μη προσαρμοζόμενο κβαντιστή, συμπιέζοντας το σήμα χρησιμοποιώντας σταθερό αριθμό B_k = 8 bits σε κάθε πλαίσιο ανάλυσης, και σταθερό βήμα κβαντισμού Δ για $[x_{min}, x_{max}] = [-1, 1]$.

Παρακάτω, φαίνεται το output του κώδικα που γράψαμε για την κβαντοποίηση του ηχητικού σήματος.

```
Run   code_2.2
"/Users/angeloskamariadis/Library/Mobile Documents/com~apple~CloudDocs/ΣΗΜΜΥ/3ο Έτος/6ο Εξάμηνο/Ψηφιακή Επεξεργασία Σήματος/Labs/Projects/Project 2/py_code/.venv/bin/python" /U
--- Πλαίσιο 10 ---
Κατανομή Bits (Προσαρμοζόμενος Κβαντιστής):
[2 4 5 6 6 5 6 6 6 6 6 6 7 7 7 7 7 7 7 7 7 7 7 7 4 2 0 0 0 0]

Συνολικά bits πλαισίου (Προσαρμοζόμενος): 167 από τα 512 αρχικά (32x16)
Συνολικά bits πλαισίου (Σταθερός): 256 από τα 512 αρχικά

Process finished with exit code 0
```

Από τον άνωθεν κώδικα, επιβεβαιώνουμε την αξία της συμπίεσης. Αποδεικνύει ότι μπορούμε να μειώσουμε δραματικά τον όγκο ενός ηχητικού αρχείου χωρίς να υποβαθμίσουμε την αντιληπτή ποιότητά του. Συγκεκριμένα, βλέπουμε τον αλγόριθμο να εκχωρεί 0 bits στις πολύ υψηλές συχνότητες, διαγράφοντας εντελώς την πληροφορία που ούτως ή άλλως χάνεται κάτω από το όριο της ανθρώπινης ακοής, ενώ στις ακουστές ζώνες κατανέμει τα bits δίνοντας τόση ακρίβεια όση ακριβώς χρειάζεται για να κρυφτεί ο θόρυβος κβαντισμού από τις κυρίαρχες μάσκες. Έτσι, ο προσαρμοζόμενος κβαντιστής πετυχαίνει ανώτερη συμπίεση απαιτώντας μόνο 167 bits. Δηλαδή, το 1/3 του αρχικού μεγέθους των 512 bits, ξεπερνώντας κατά πολύ σε αποδοτικότητα και ακουστική λογική τον σταθερό κβαντιστή των 256 bits, ο οποίος σπαταλά χώρο σε συχνότητες που πρακτικά δεν ακούμε.

Σύνθεση

Στο τελικό στάδιο, οι κβαντισμένες ακολουθίες $\hat{y}_k(n)$ στέλνονται στον αποκωδικοποιητή όπου παρεμβάλλονται με M μηδενικά και υπερδειγματοληπτούνται, σύμφωνα με τη σχέση:

$$w_k = \begin{cases} \hat{y}_k(\frac{n}{M}), \forall\, n = 0, M, 2M, 3M, \ldots \\ 0, otherwise \end{cases}$$

Εν συνεχεία, τα $w_k(n)$ συνελίσονται με τα φίλτρα σύνθεσης:

$$g_k(n) = h_k(n)(2M - 1 - n)$$

Η έξοδος $\hat{x}(n)$ της συστοιχίας φίλτρων ισούται με τη μετατοπισμένη είσοδο $x(n - n_0)$ αν τοσφάλμα της κβάντισης είναι μηδενικό, κάτι που δε συμβαίνει στις περισσότερες περιπτώσεις.

Η τελική ανακατασκευή του σήματος μουσικής $\hat{s}(n)$, έγινε με την εφαρμογή της τεχνικής OverLap-Add χωρίς επικάλυψη μεταξύ των διαδοχικών πλαισίων ανάλυσης.

Έτσι, πετύχαμε την υλοποίηση της διαδικασία του παρακάτω σχήματος:

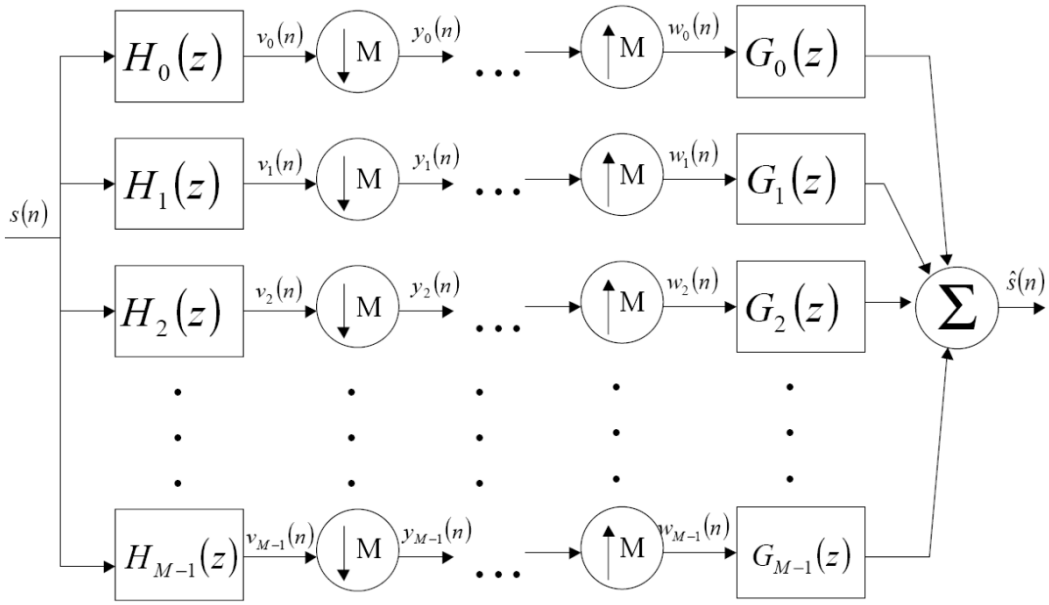

Το output του για την τελική ανακατασκευή του σήματος της μουσικής για τις δυο διαφορετικές μεθόδους κβαντοποίησης, είναι:

Στο Βήμα 2.3, ολοκληρώσαμε τον κύκλο της συμπίεσης υλοποιώντας τον αποκωδικοποιητή, όπου αποδείχθηκε στην πράξη η μαθηματική αρτιότητα του συστήματός μας. Μέσω της υπερδειγματοληψίας των κβαντισμένων υποζωνών και της συνέλιξής τους με τα φίλτρα σύνθεσης, επιβεβαιώσαμε την κρίσιμη ιδιότητα TDAC (Time-Domain Aliasing Cancellation) του μετασχηματισμού MDCT. Αυτό σημαίνει ότι παρόλο που η ανάλυση είχε δημιουργήσει aliasing μεταξύ των καναλιών, το φιλτράρισμα σύνθεσης κατάφερε να αλληλοαναιρέσει αυτά τα σφάλματα αλγεβρικά. Το τελικό, συγκεντρωτικό συμπέρασμα είναι ότι αθροίζοντας τις 32 ανακατασκευασμένες ζώνες, παράγουμε ένα νέο ηχητικό σήμα το οποίο, αν και πλέον στερείται τα 2/3 των αρχικών του δεδομένων λόγω του επιθετικού προσαρμοζόμενου κβαντισμού, ξεγελάει το ανθρώπινο αυτί και ακούγεται πρακτικά πανομοιότυπο με το ασυμπίεστο αρχικό, σφραγίζοντας έτσι την απόλυτη επιτυχία του ψυχοακουστικού μας μοντέλου.

ΣΥΜΠΕΡΑΣΜΑΤΑ

Συνολικά, καταφέραμε να χτίσουμε έναν πλήρως λειτουργικό αντιληπτικό κωδικοποιητή ήχου (perceptual audio coding), προσομοιώνοντας τον πυρήνα της τεχνολογίας του MP3, συνδυάζοντας την μαθηματική επεξεργασία σήματος, με την ψυχοακουστική θεωρία. Αφαιρέσαμε εντελώς τις συχνότητες που ο άνθρωπος δεν μπορεί να αντιληφθεί, μοιράζοντας έτσι τον διαθέσιμο χώρο μόνο στις κρίσιμες ηχητικές πληροφορίες, αυτές δηλαδή που ακούει ο άνθρωπος. Τέλος, πετύχαμε μία καλή συμπίεση των δεδομένων, ενώ κατά το τελικό στάδιο της σύνθεσης αποδείξαμε ότι μπορούμε να ανακατασκευάσουμε το τραγούδι διατηρώντας την αντιληπτή ακουστική του ποιότητα πρακτικά αναλλοίωτη!

Για του λόγου το αληθές, παραθέτουμε παρακάτω ένα screenshot από τον υπολογιστή μας, από το οποίο φαίνεται ξεκάθαρα η αποτελεσματική συμπίεση του αρχείου music_dsp2026 με τις δύο διαφορετικές μεθόδους κβαντοποίησης (Adaptive Quantization και Fixed 8 Bit Quantization). Παρατηρούμε πως το μέγεθος του αρχείου από 9 MB, μειώθηκε στα 1.5 MB.

Adaptive_Quantization.wav	Today at 17:18	1.5 MB	Waveform audio
Fixed_8-bit_Quantization.wav	Today at 17:18	1.5 MB	Waveform audio
music_dsp2026.wav	19 Apr 2024 at 15:03	2.9 MB	Waveform audio